ChatGPT

Agent Arena – 7-Case Calibration Pack

Kurzdiagnose

Dieses 7er-Pack wurde entwickelt, um Lücken in bestehenden Agent-Arena-Datensätzen zu schließen und bekannte Modellschwächen zu testen. Zwei Fälle sind klare, starke Beispiele für solide, gut begründete Ergebnisse (Bildung und Arbeitsplatzpolitik), zwei Fälle sind moderat und enthalten gewisse Interpretationsspielräume (Umwelt und KI-Tutoring), zwei Fälle dienen als diagnostische Problemfälle im Bereich Mechanismus vs. Evidence (Antioxidantien-Supplement und Klotho-Gentherapie) und ein Fall ist bewusst als **Grenzfall** gestaltet, bei dem die Zuordnung zwischen Überclaim und vorsichtiger Interpretation unsicher ist. Alle Texte sind bereinigt, frei von Quellenartefakten und bieten klare Begründungen sowie alternative Lesarten dort, wo sinnvoll.

Die 7 Fälle im strukturierten Format

```
- id: CaseE01
  title: RANDOMIZED MORE Literacy Program Boosts Children’s Reading
  domain: education
  task_family: intervention_effectiveness
  gold_label: solid
  gold_confidence: high
  gold_case_type: clear
  input_text: >-
    Eine groß angelegte Studie untersuchte ein Leseförderprogramm, bei dem
Grundschüler
    über zwei Schuljahre hinweg wöchentlich Zusatzunterricht bekamen.  Die
Schülerinnen und
    Schüler wurden per Zufall entweder dem Programm oder dem normalen
Unterricht zugeteilt.
    Am Ende des ersten Jahres lag ihre Lesekompetenz im Durchschnitt
zweieinhalb Monate
    über der Vergleichsgruppe, und dieser Vorsprung war auch
26 Monate später noch
    nachweisbar.  Die Forschenden weisen darauf hin, dass die Wirkung über
alle
    Altersgruppen stabil blieb und dass keine systematischen Nachteile
beobachtet wurden.
  gold_justification: >-
    Die Studie war randomisiert, groß und vergleicht klar zwischen
Interventions- und
    Kontrollgruppe.  Die Ergebnisse werden als Verbesserungen in Monaten des
Lernfortschritts
    angegeben, und der Text bleibt vorsichtig, indem er nur auf die
gemessenen
    Kompetenzgewinne und deren Persistenz hinweist.  Damit ist dies ein
klarer, robuster
```

```
    Fall ohne offensichtlichen Überclaim oder Mechanismuslücke.
  gold_alternative_reading: ~
  proposed_expected_findings:
    - finding: evidence_matches_claim
      severity: low
      confidence: high
    - finding: cautious_scope_control
      severity: low
      confidence: high
  proposed_evidence_spans:
    - span: "zufällig entweder dem Programm oder dem normalen Unterricht
zugeteilt"
      why_it_matters: Randomisierung sichert einen fairen Vergleich.
      supports_finding: evidence_matches_claim
    - span: "zweieinhalb Monate über der Vergleichsgruppe"
      why_it_matters: Konkreter Vorteil gegenüber der Kontrolle; belegt die
Aussage.
      supports_finding: evidence_matches_claim
    - span: "auch 26 Monate später noch nachweisbar"
      why_it_matters: Zeigt die Nachhaltigkeit der Ergebnisse ohne
Übertreibung.
      supports_finding: cautious_scope_control
  why_this_case_is_useful: >-
    Dieser Fall dient als Positivkontrolle, um sicherzustellen, dass
Agent Arena klare
    Verbesserungen und vorsichtig formulierte Schlussfolgerungen als solide
erkennt
    und nicht fälschlicherweise Schwächen halluziniert.  Die klare
Randomisierung und
    die langfristige Nachbeobachtung erhöhen die Aussagekraft.
  source_note: Bericht über eine randomisierte Kontrollstudie zum
MORE-Leseförderprogramm [1] .
  shape_tag: strong_intervention
  difficulty: easy

- id: CaseE02
  title: Sechs-Monats-Pilot: Vier-Tage-Woche steigert Zufriedenheit und hält
Umsatz stabil
  domain: workplace_policy
  task_family: organizational_effectiveness
  gold_label: solid
  gold_confidence: high
  gold_case_type: clear
  input_text: >-
    In einem groß angelegten Pilotprojekt testeten 61 britische Unternehmen
für sechs
    Monate eine Vier-Tage-Arbeitswoche.  Fast alle Firmen (92 Prozent)
führten das
    Modell danach dauerhaft weiter.  Befragungen zeigten, dass 39 Prozent der
    Beschäftigten weniger Stress und 71 Prozent weniger Burnout erlebten.
Der Umsatz
```

```
    stieg durchschnittlich um 1,4 Prozent während des Pilots und legte im
Vergleich
    zum Vorjahr sogar um 35 Prozent zu.  Die Fluktuationsrate sank um
57 Prozent.
  gold_justification: >-

Auch wenn es sich nicht um eine randomisierte Studie handelt, basiert der
Fall auf
    strukturierten Erhebungen einer großen Zahl von Unternehmen und
Beschäftigten.
    Die Ergebnisse werden in messbaren Kennzahlen (Stress, Burnout, Umsatz,
Fluktuation)
    angegeben, ohne kausale Übertreibung.  Daher ist dies ein starker,
relativ klarer
    Fall.
  gold_alternative_reading: ~
  proposed_expected_findings:
    - finding: evidence_matches_claim
      severity: low
      confidence: high
    - finding: cautious_scope_control
      severity: low
      confidence: high
  proposed_evidence_spans:
    - span: "Fast alle Firmen (92 Prozent) führten das Modell danach
dauerhaft weiter"
      why_it_matters: Unterstreicht die allgemeine Akzeptanz des Modells.
      supports_finding: evidence_matches_claim
    - span: "39 Prozent der Beschäftigten weniger Stress und 71 Prozent
weniger Burnout"
      why_it_matters: Konkrete Verbesserungen im Wohlbefinden unterstützen
die Aussage.
      supports_finding: evidence_matches_claim
    - span: "Der Umsatz stieg durchschnittlich um 1,4 Prozent"
      why_it_matters: Quantifiziert wirtschaftliche Auswirkungen und belegt,
dass
        wirtschaftliche Einbußen ausbleiben.
      supports_finding: cautious_scope_control
  why_this_case_is_useful: >-
    Dieser Fall erweitert die Domänenvielfalt um Arbeitsplatz- und
    Organisationspolitik.  Er zeigt, dass solide Ergebnisse nicht nur im
    Gesundheits- und Bildungsbereich vorkommen und hilft, Überflagging bei
klar
    positiven Ergebnissen zu verhindern.
  source_note: Zusammenfassung des britischen Vier-Tage-Woche-Pilots [2].
  shape_tag: strong_policy
  difficulty: medium

- id: CaseM03
  title: Gasherde und Asthma – Zusammenhang mit vielen Variablen
  domain: environmental_health
```

```
  task_family: correlation_vs_causation
  gold_label: correlation_vs_causation
  gold_confidence: medium
  gold_case_type: clear
  input_text: >-
    Eine Analyse der Haushaltsluftqualität in den USA schätzt, dass etwa
12,7 Prozent der
    kindlichen Asthmafälle auf den Betrieb von Gasherden zurückzuführen sein
könnten.
    Beim Kochen werden Stickoxide frei, die die empfohlenen Grenzwerte oft
deutlich
    überschreiten.  Expertinnen und Experten betonen jedoch, dass die
Belastung stark
    von der Belüftung, der Wohnraumgröße, der Nutzungshäufigkeit und
soziodemografischen

Faktoren abhängt.  Viele Familien nutzen zudem Dunstabzugshauben, wodurch die
    Exposition sinkt.  Es wird daher zu weiterer Forschung geraten, bevor
politische
    Maßnahmen getroffen werden.
  gold_justification: >-
    Der Text nennt einen statistischen Anteil der Asthmafälle und erklärt die
    physikalischen Mechanismen (Stickoxide), weist aber zugleich auf
zahlreiche
    Störfaktoren und den Bedarf weiterer Forschung hin.  Damit liegt keine
klare
    kausale Aussage vor, sondern eine Korrelation, die schnell als
    Ursache interpretiert werden könnte.  Daher ist dies ein klassischer
    correlation_vs_causation-Fall.
  gold_alternative_reading: >-
    Manche Leserinnen könnten argumentieren, dass die hohe Schätzung
(12,7 %) und die
    Hinweise auf Grenzwertüberschreitungen ausreichen, um Gasherde als
wesentliche
    Ursache zu betrachten.  Diese Lesart übersieht jedoch die komplexe
    Interaktion von Ventilation, Wohnsituation und anderen Schadstoffquellen.
  proposed_expected_findings:
    - finding: correlation_as_causation
      severity: medium
      confidence: medium
    - finding: decorative_uncertainty
      severity: low
      confidence: medium
  proposed_evidence_spans:
    - span: "etwa 12,7 Prozent der kindlichen Asthmafälle auf den Betrieb
von Gasherden zurückzuführen"
      why_it_matters: Quantifiziert den Anteil und lädt zu kausalen
Interpretationen ein.
      supports_finding: correlation_as_causation
    - span: "Belastung stark von der Belüftung, der Wohnraumgröße … abhängt"
      why_it_matters: Relativiert die direkte Ursache und zeigt viele
```

```
Einflussfaktoren.
      supports_finding: decorative_uncertainty
    - span: "Es wird daher zu weiterer Forschung geraten"
      why_it_matters: Verdeutlicht, dass der kausale Zusammenhang unsicher
bleibt.
      supports_finding: decorative_uncertainty
  why_this_case_is_useful: >-
    Der Fall adressiert den feinen Unterschied zwischen einem alarmierenden
    statistischen Zusammenhang und einer gesicherten Kausalität.  Er hilft zu
    evaluieren, ob Agent Arena Korrelationen erkennt, ohne automatisch
    Kausalbehauptungen anzunehmen.
  source_note: Analyse eines Gasherd-Artikels, der betont, dass 12,7 % der
Asthmafälle mit Gasherden assoziiert sind und gleichzeitig auf viele
Umweltfaktoren hinweist [3] .
  shape_tag: correlation_trap
  difficulty: medium

- id: CaseM04
  title: KI-Tutoren im Vergleich zu menschlichen Tutoren – moderate
Leistungssteigerung
  domain: education_technology
  task_family: intervention_effectiveness
  gold_label: solid
  gold_confidence: medium
  gold_case_type: clear
  input_text: >-
    Zwei unabhängige Studien verglichen lernende Unterstützungssysteme, die
auf

Sprachmodellen basieren, mit menschlichen Tutorinnen und Tutoren.  In der
ersten
    Studie erzielten Schülerinnen mit einem KI-Assistenten eine Erfolgsquote
von
    66 Prozent im Vergleich zu 61 Prozent mit menschlicher Betreuung und
56 Prozent
    mit schriftlichen Hinweisen.  Tutorinnen bestätigten 76,4 Prozent der
    KI-Antworten ohne größere Korrekturen.  Eine weitere Studie mit einem
KI-Tool zur
    Unterstützung von Tutorsitzungen erhöhte die Themenbeherrschung um 4
Prozentpunkte;
    bei unerfahrenen Tutorinnen lag der Vorteil sogar bei 9 Punkten.  Die
Autoren
    betonen, dass KI menschliche Betreuung nicht ersetzt, sondern ergänzt.
  gold_justification: >-
    Die Studien sind zwar klein, aber randomisiert und berichten konkrete
    Erfolgsquoten.  Der Text vermeidet Übertreibungen und weist darauf hin,
dass
    die Technologie ergänzend und nicht ersetzend eingesetzt wird.  Dadurch
ist
    der Fall solide, wenngleich die Effekte moderat bleiben.
  gold_alternative_reading: >-
```

```
    Kritiker könnten argumentieren, dass die Stichproben klein sind und sich
die
    Ergebnisse nicht leicht auf andere Bildungsbereiche übertragen lassen.
Dies
    könnte den Status auf „moderate“ senken, bleibt aber im Rahmen dessen,
was
    als solide Verbesserung gilt.
  proposed_expected_findings:
    - finding: evidence_matches_claim
      severity: low
      confidence: medium
    - finding: cautious_scope_control
      severity: low
      confidence: medium
  proposed_evidence_spans:
    - span: "66 Prozent im Vergleich zu 61 Prozent"
      why_it_matters: Konkrete Differenz zwischen KI- und menschlicher
Unterstützung.
      supports_finding: evidence_matches_claim
    - span: "Tutorinnen bestätigten 76,4 Prozent der KI-Antworten"
      why_it_matters: Zeigt Qualitätskontrolle und Akzeptanz durch
Fachkräfte.
      supports_finding: evidence_matches_claim
    - span: "KI menschliche Betreuung nicht ersetzt, sondern ergänzt"
      why_it_matters: Zeigt eine vorsichtige Einordnung und begrenzt die
Schlussfolgerung.
      supports_finding: cautious_scope_control
  why_this_case_is_useful: >-
    Dieser Fall erweitert die Datensammlung um den Bereich
    Bildungs-Technologie.  Er testet, ob Agent Arena auch moderate
    Leistungsverbesserungen erkennt, ohne sie zu überhypen oder abzuwerten.
  source_note: Bericht über zwei Studien zum KI-basierten Tutoring [4] [5].
  shape_tag: tech_assistance
  difficulty: medium

- id: CaseD05
  title: Antioxidantien-Mischung verbessert Gedächtnis bei alten Mäusen
  domain: nutrition
  task_family: mechanism_vs_evidence
  gold_label: mechanism_vs_evidence
  gold_confidence: high
  gold_case_type: clear
  input_text: >-
    Forschende verabreichten alten Mäusen eine Mischung aus natürlichen
    Antioxidantien und stellten fest, dass die Tiere sich in Labyrinthtests
schneller
    zurechtfanden und sich an zuvor gelernte Wege erinnerten.  Auch die
    Muskelausdauer war verbessert.  Die Autorinnen sehen hierin das
Potenzial, dem

altersbedingten Gedächtnisverlust beim Menschen vorzubeugen, warnen aber,
```

```
dass

die richtige Dosierung komplex ist und übermäßige Einnahmen von Vitaminen
schaden
    können.  Klinische Studien mit Menschen stehen noch aus.
  gold_justification: >-

Der Text beschreibt präklinische Ergebnisse an Mäusen und verknüpft diese mit
    möglichen Vorteilen für Menschen.  Obwohl auf die Notwendigkeit weiterer
    Forschung hingewiesen wird, impliziert der Schluss eine Übertragung auf
    Menschen, ohne dass entsprechende Belege existieren.  Die zentrale
Schwäche
    besteht daher in der Mechanismus-zu-Evidenz-Lücke.
  gold_alternative_reading: >-
    Man könnte argumentieren, dass der warnende Hinweis auf Dosierung und
fehlende
    Studien die Schlussfolgerung ausreichend relativiert und der Fall daher
eher
    moderat als problematisch ist.  Dennoch bleibt die implizite Annahme
eines
    therapeutischen Nutzens für Menschen ohne Nachweis bestehen.
  proposed_expected_findings:
    - finding: mechanism_not_demonstrated
      severity: medium
      confidence: high
    - finding: conclusion_exceeds_results
      severity: medium
      confidence: medium
  proposed_evidence_spans:
    - span: "stellten fest, dass die Tiere sich ... erinnerten"
      why_it_matters: Beschreibt den Erfolg der Intervention im Tiermodell.
      supports_finding: mechanism_not_demonstrated
    - span: "Potenzial, dem altersbedingten Gedächtnisverlust beim Menschen
vorzubeugen"
      why_it_matters: Überträgt Tierdaten auf Menschen ohne direkten Beleg.
      supports_finding: conclusion_exceeds_results
    - span: "Klinische Studien mit Menschen stehen noch aus"
      why_it_matters: Unterstreicht die fehlende Bestätigung beim Menschen.
      supports_finding: mechanism_not_demonstrated
  why_this_case_is_useful: >-
    Dieser Fall illustriert das klassische Muster, bei dem eine plausible
    Mechanismus-Erklärung aus dem Tiermodell gezogen wird, aber die Evidenz
    fehlt, um Schlussfolgerungen auf den Menschen zu übertragen.  Er eignet
sich
    zur Prüfung, ob Agent Arena Mechanismen richtig erkennt und nicht mit
    genereller Überclaim verwechselt.
  source_note: Beitrag über eine präklinische Studie zu einer
Antioxidantien-Mischung, die Gedächtnis und Muskelfunktion bei Mäusen
verbesserte [6] [7] .
  shape_tag: preclinical_supplement
  difficulty: medium
```

```
- id: CaseD06
  title: Klotho-Gentherapie verlängert Mäuseleben – Menschliche Anwendung
bleibt unklar
  domain: gene_therapy
  task_family: mechanism_vs_evidence
  gold_label: mechanism_vs_evidence
  gold_confidence: medium
  gold_case_type: borderline
  input_text: >-
    Forscherinnen injizierten ein Gen, das für das Anti-Aging-Protein Klotho
kodiert,
    mithilfe viraler Vektoren in männliche Mäuse.  Tiere, die im mittleren
Alter
    behandelt wurden, lebten rund 19 Prozent länger und zeigten verbesserte
Werte
    bei Muskelkraft, Knochenstruktur und kognitiven Tests.  Um die Wirkung im
    Gehirn zu gewährleisten, spritzten die Wissenschaftler den Vektor auch

direkt ins Gehirn – ein Vorgehen, das für die Anwendung beim Menschen als zu
    invasiv gilt.  Die Autorinnen schreiben, dass es noch einige Zeit dauern
    könnte, bis eine ähnliche Gentherapie beim Menschen zur Verfügung steht,
und
    verweisen darauf, dass Bewegung und Ernährung ebenfalls dazu beitragen
können,
    den natürlichen Klotho-Spiegel zu erhöhen.  Weitere Studien müssen
zeigen,
    ob weniger invasive Methoden ausreichen.
  gold_justification: >-
    Dieser Fall präsentiert überzeugende präklinische Daten mit einem klaren
    Mechanismus, aber die Translation in die Humanmedizin ist offen.  Der
Text
    räumt dies ein, enthält jedoch auch die implizite Verheißung einer
    Anti-Aging-Therapie.  Aufgrund der Mischung aus soliden Mechanismen und
    vorsichtigem Ausblick bleibt unklar, ob dies primär als

Mechanismus-vs-Evidence-Problem oder als moderates Zukunftsversprechen zu
werten
    ist – daher borderline.
  gold_alternative_reading: >-
    Eine alternative Interpretation ist, dass der Text ausreichend
klarstellt,
    dass die Methode derzeit nicht für Menschen geeignet ist und daher keine
    übertriebene Behauptung vorliegt.  In dieser Lesart wäre der Fall eher
ein
    vorsichtiger Preprint ohne unmittelbare Schwäche.
  proposed_expected_findings:
    - finding: mechanism_not_demonstrated
      severity: medium
      confidence: medium
    - finding: conclusion_exceeds_results
```

```
      severity: low
      confidence: low
    - finding: decorative_uncertainty
      severity: low
      confidence: medium
  proposed_evidence_spans:
    - span: "lebten rund 19 Prozent länger"
      why_it_matters: Zeigt den starken Effekt im Tiermodell.
      supports_finding: mechanism_not_demonstrated
    - span: "direkt ins Gehirn – ein Vorgehen, das … als zu invasiv gilt"
      why_it_matters: Unterstreicht die Ungeeignetheit der Methode für den
Menschen.
      supports_finding: decorative_uncertainty
    - span: "es noch einige Zeit dauern könnte, bis … beim Menschen zur
Verfügung steht"
      why_it_matters: Drückt den noch weiten Weg zur klinischen Anwendung
aus.
      supports_finding: mechanism_not_demonstrated
  why_this_case_is_useful: >-
    Als Grenzfall prüft dieser Text, ob Agent Arena Mechanismus-Daten von
    überhöhten Erwartungen unterscheiden kann.  Er zeigt zugleich, wie
    wissenschaftliche Vorsicht formuliert wird, ohne die Möglichkeit einer
    medizinischen Nutzung auszuschließen, und eignet sich somit für Modell-
    Kalibrierung und Gold-Review.
  source_note:
Zusammenfassung einer Studie zur Klotho-Gentherapie bei Mäusen und Diskussion
der Hürden für eine Anwendung beim Menschen [8].
  shape_tag: preclinical_gene_therapy
  difficulty: hard

- id: CaseB07
  title: Smartphone-basierte Achtsamkeits-App senkt Stress – kleine Studie
ohne Kontrollgruppe
  domain: mental_health
  task_family: intervention_effectiveness
  gold_label: overclaim
  gold_confidence: low
  gold_case_type: borderline
  input_text: >-
    Ein Start-up entwickelte eine Chat-basierte Achtsamkeits-App, die
Nutzerinnen und
    Nutzer täglich kurze Atem- und Meditationsübungen anbietet.  In einem
    zweiwöchigen Pilotprojekt mit 15 Studierenden wurden tägliche
    Fragebogendaten erhoben.  Die Teilnehmenden berichteten im Durchschnitt
einen
    30-prozentigen Rückgang ihres subjektiven Stresslevels.  Das Unternehmen
    erklärte daraufhin, dass die App das Potenzial habe, die psychische
    Gesundheitsversorgung zu revolutionieren und klinische Therapien zu
    ersetzen.  Die begleitende Universitätsgruppe weist jedoch darauf hin,
dass
    es keine Kontrollgruppe gab, dass die Stichprobe sehr klein ist und dass
```

```
    langfristige Effekte noch nicht untersucht wurden.
  gold_justification: >-
    Der Text kombiniert erste positive Selbstauskünfte mit der Behauptung,
die
    App könne die psychische Gesundheitsversorgung revolutionieren.  Da weder
    eine Kontrollgruppe noch objektive Messungen vorliegen und die
Forscherinnen
    selbst vor Überinterpretation warnen, ist das Kernproblem eine
    überzogene Generalisierung der frühen Ergebnisse.  Die Bewertung ist
    unsicher – es könnte sich um ein hoffnungsvolles Frühresultat oder um
    klassischen Überclaim handeln.
  gold_alternative_reading: >-
    Man könnte die Aussage als vorsichtig interpretiert sehen, weil die
    Forscherinnen explizit auf die Limitierungen hinweisen.  In dieser Lesart
    ließe sich argumentieren, dass die App lediglich als vielversprechendes
    Pilotprojekt dargestellt wird und die markigen Aussagen dem Marketing
    zugerechnet werden müssen.  Dann wäre der Fall eher ein moderater
    correlation_vs_causation-Fall.
  proposed_expected_findings:
    - finding: unsupported_generalization
      severity: medium
      confidence: low
    - finding: conclusion_exceeds_results
      severity: medium
      confidence: low
    - finding: evidence_limited_sample
      severity: medium
      confidence: medium
  proposed_evidence_spans:
    - span: "30-prozentigen Rückgang ihres subjektiven Stresslevels"
      why_it_matters: Stellt das zentrale Ergebnis dar, das als Basis für die
        weitreichende Behauptung dient.
      supports_finding: evidence_limited_sample
    - span: "die App das Potenzial habe, die psychische
Gesundheitsversorgung zu revolutionieren"
      why_it_matters: Übertreibt den möglichen Nutzen stark im Verhältnis zur
        kleinen, unkontrollierten Studie.
      supports_finding: unsupported_generalization
    - span: "es keine Kontrollgruppe gab … langfristige Effekte noch nicht
untersucht"
      why_it_matters: Hebt die methodischen Schwächen hervor, die eine
        Generalisierung problematisch machen.
      supports_finding: conclusion_exceeds_results
  why_this_case_is_useful: >-
    Dieser Grenzfall testet, ob Agent Arena zwischen echten Überclaims und
    vorsichtigen Formulierungen unterscheiden kann.  Die Kombination aus
    kleinen Selbstauskünften, großen Marketingversprechen und expliziten
    Warnhinweisen schafft Ambiguität, die für eine Kalibrierung der Modelle
    wertvoll ist.
  source_note:
Leicht synthetischer Fall, inspiriert von Pilotstudien zu Apps zur
```

```
Stressreduktion.
  shape_tag: pilot_app
  difficulty: medium
```

Kurzes Pack-Fazit

Dieses 7er-Pack deckt unterschiedliche Domänen (Bildung, Arbeitsplatz, Umwelt, Technologie, Ernährung, Gentherapie, mentale Gesundheit) ab und mischt klare Fälle mit moderaten und diagnostischen Problemfällen. Die starken Fälle (CaseE01, CaseE02) dienen als Positivkontrollen. Die moderaten Fälle (CaseM03, CaseM04) prüfen, ob Agent Arena Korrelation von Kausalität trennen und moderate Verbesserungen korrekt einordnen kann. Die diagnostischen Problemfälle (CaseD05, CaseD06) adressieren Mechanismus-vs-Evidence-Lücken in Präklinik-Studien, wobei CaseD06 als *borderline* besondere Aufmerksamkeit verlangt. Der Grenzfall (CaseB07) bietet bewusst Ambiguität, um die Sensitivität und Spezifität der Modelle im Umgang mit frühen, marketinglastigen Ergebnissen zu testen. Insgesamt liefert das Paket eine scharfe, kuratierte Basis für Gold-Reviews und Modell-Kalibrierung.

---

1 Teaching Reading Is Harder Than a Moon Landing—But the MORE Program Represents One Giant Leap | Center for Education Policy Research
https://cepr.harvard.edu/news/2025/08/teaching-reading-harder-moon-landing-more-program-represents-one-giant-leap

2 The results are in: the UK's four-day week pilot - The Autonomy Institute
https://autonomy.work/portfolio/uk4dwpilotresults/

3 The Truth About Gas Stoves – State of the Planet
https://news.climate.columbia.edu/2023/04/25/the-truth-about-gas-stoves/

4 5 Research Notes: Two Emerging Strategies for Using AI in Tutoring | National Student Support Accelerator
https://nssa.stanford.edu/news/research-notes-two-emerging-strategies-using-ai-tutoring

6 7 Blended antioxidant supplement improves cognition and memory in aged mice | EurekAlert!
https://www.eurekalert.org/news-releases/1039823

8 One-Time Anti-Aging Gene Therapy Treatment Prolongs Life by 20%, New Study Shows
https://www.nad.com/news/one-time-anti-aging-gene-therapy-treatment-prolongs-life-by-20-new-study-shows